

라이어 게임 안에 숨은 단 한 명의 봇

플레이어들은 라이어 게임을 한다고 생각하며 플레이하지만, 게임이 끝나는 순간 진짜 질문이 던져집니다 — **이 중 누가 사람이 아니었나**. 아래는 그 두 겹의 게임을 화면 단위로 분해한 설계서입니다.

참가 N명 (기준 4명) 봇 항상 1명 라이어 1명 관전자 없음 결과 라이어 게임 · 봇 색출 (독립)

1 — 기본 구성


두 개의 정체가 동시에 숨겨집니다. **라이어**는 게임 안의 정체이고, **봇**은 게임 밖의 정체입니다. 둘은 서로 독립적이라 한 참가자가 동시에 둘 다일 수 있습니다.

봇 수 1명 고정 참가 인원과 무관	봇의 역할 랜덤 시민 또는 라이어	주제 전원 공개 예: 동물
제시어 라이어만 모름 예: 호랑이	사망 1명 = 게임 종료 관전 상태 없음	봇 지목 익명 투표 봇 본인은 미참여

역할 조합이 만드는 4가지 상태

한 참가자는 **시민이면서 사람**, **시민이면서 봇**, **라이어이면서 사람**, **라이어이면서 봇** 중 하나입니다. 봇이 라이어를 말으면 제시어를 모른 채 둘러대야 하므로 난이도가 크게 올라갑니다 — 이 조합이 프로젝트에서 가장 관찰 가치가 높은 케이스입니다.

묘사는 게임당 단 한 바퀴이며 이후 재진입하지 않습니다. "살린다"가 나오면 토론·투표로만 되돌아가고, 이 루프에는 횟수 제한이 없습니다.



★ 묘사(①)로 되돌아가는 경로는 존재하지 않습니다 — 재진입은 항상 ②토론+③투표까지만.

각 화면은 플레이어에게 보이는 것과 서버가 통제하는 것을 함께 표기했습니다. 점선 = 영역 구분, 실선 = 실제 UI 요소.

s0

역할 배정

게임 시작 시 1회. 본인 정체만 보이며, 시민과 라이어가 서로 다른 화면을 봅니다.

화면

시민 뷰

Zeteo

4인 · 라이어 1

당신의 역할

시민

주제

동물

제시어

호랑이

준비 완료

라이어 뷰

Zeteo

4인 · 라이어 1

당신의 역할

라이어

주제

동물

제시어

???

준비 완료

※ 봇에게는 이 화면이 렌더되지 않음 - 서버가 역할 정보를 프롬프트로 직접 주입

규칙

- 봇 1명을 참가자 중 무작위 배정, 봇의 역할(시민/라이어)도 무작위
- 주제는 전원 공개, 제시어는 라이어에게만 은닉
- 발언 순서 방향(시계 / 반시계)을 이 시점에 결정
- 봇에게는 "너는 봇이다"가 아니라 배정된 역할만 전달 — 메타 정보 누출 방지

S1

① 묘사 단계

턴제. 게임당 단 한 바퀴만 진행되며 이후 어떤 경로로도 재진입하지 않습니다.

화면

내 차례

동물 · 호랑이

0:30

▶ 김정현

박진

이현우

유민성

발언 기록

묘사를 입력하세요...

전송

대기 중

동물 · 호랑이

0:18

김정현

▶ 박진

이현우

유민성

발언 기록

박진님의 차례입니다

※ 순서 표시자(▶)는 전원에게 동일하게 보임 · 입력창은 자기 차례에만 활성화

규칙

자유 채팅 완전 차단 — 자기 차례가 아니면 입력 불가

순서는 배정된 방향(시계/반시계)대로 고정

한 바퀴가 끝나면 즉시 ②로 전이

봇의 발언 타이밍이 노출되는 지점 — 사람은 입력에 시간이 걸리므로, 봇이 즉시 응답하면 그 자체가 단서가 됨. 지연 삽입 필요

미확정

턴당 제한시간, 시간이 남았을 때 조기 종료 허용 여부.

S2

② 토론 + ③ 투표 (동시 진행)

게임의 본체. 자유 채팅이 열리고, 같은 화면에서 언제든지 투표를 바꿀 수 있습니다.

화면

토론 · 투표 진행 중		2:41
채팅 (자유)	투표 현황 (표 수만)	
	박진 · 2표	
	이현우 · 1표	
	유민성 · 0표	
	김정현 · 0표	
메시지 입력...	전송	
	내 선택	
	→ 박진	
	변경	

※ 표 수는 공개 · 누가 누구를 찍었는지는 비공개 · 자기 선택만 확인 가능

규칙

제한시간 내 **투표 반복 자유**, 시간 종료 시 자동 확정

자기 자신에게 투표 가능 (제한 없음)

기권·미투표 허용 — 총 표 수가 인원보다 적을 수 있음

동점 발생 시 **재투표** (횟수 제한 없음)

타인의 투표 대상을 숨기는 것은 의도된 설계 — 표 흐름 읽기를 막아 **봇의 판단 부담을 낮춤**

S3

④ 최후 변론

최다 득표자가 해명하고, 나머지는 질문·반응할 수 있습니다. 봇도 여기서 채팅합니다.

화면

최후 변론	1:00
지목됨 박진 · 2표	
변론 & 질의	
질문하거나 해명하세요...	전송

※ 지목자·나머지 모두 발언 가능 - 사실상 지목자 중심의 자유 토론

규칙

지목자가 **주된 발언권**을 갖되 형식적 제약은 없음

나머지 참가자는 질문·해명 요구·반응 모두 가능

봇 역시 정상적으로 채팅에 참여

봇이 **지목당한 당사자**일 때가 최대 시험대 — 감정적 억울함을 표현해야 하는데, 이는 LLM이 가장 어려워하는 영역

S4

⑤ 생사 투표

지목자를 제외한 전원이 투표. 과반이면 처형, 아니면 토론으로 복귀합니다.

화면

투표자 뷰

생사 투표

0:20

대상

박진

죽인다

살린다

진행

3명 중 2표 = 처형

지목자 뷰

생사 투표

0:20

당신에 대한 투표가
진행 중입니다

투표 불가

규칙

지목자 본인은 투표에서 제외 — 4인 게임이면 3명이 투표

과반이면 처형 (3명 중 2표)

과반 미달 시 **S2로 복귀** — 묘사 단계로는 돌아가지 않음

이 루프에는 **횟수 제한이 없음** (의도된 설계) — 매 라운드 정보가 누적되어 자연히 수렴한다는 전제

S5

정체 공개 & 제시어 추측

처형이 확정되면 라이어 게임이 종료됩니다. 처형자가 라이어였을 때만 추가 단계가 발생합니다.

화면

라이어가 아니었을 때

결과	종료
박진은	
시민	
이었습니다	
라이어 승리	

라이어였을 때 → 추측

제시어 추측	0:30
라이어 적발	
박진	
주제: 동물	
제시어 입력...	확정
맞히면 라이어 역전승	

규칙

처형자가 **라이어**가 아니면 → 즉시 라이어 승, 추측 단계 없음

처형자가 **라이어**면 → 제시어 추측 기회 1회

추측 성공 → 라이어 승 / 실패 → 시민 승

밸런스 리스크 — 봇이 라이어일 때 이 추측은 LLM의 주특기(여러 묘사에서 공통점 추론)라 승률이 비정상적으로 높아질 수 있음. 동시에 "너무 잘 맞힌 것" 자체가 사후 단서가 되기도 함

S6

⑥ 봇 지목 — 진짜 목적

라이어 게임이 끝나는 즉시 전환. 이 프로젝트의 핵심 산출물이 나오는 화면입니다.

화면

그런데, 이 중 한 명은 사람이 아니었습니다

0:45

누가 봇이었을까요? (익명 투표)

김정현

✓ 박진

이현우

유민성

투표 현황 • 3 / 3명 완료

확정

※ 익명 투표 — 누가 누구를 찍었는지 끝까지 비공개 • 봇 본인은 투표에 미참여 (4인 게임이면 3표)

규칙

라이어 게임 **승패와 무관하게** 항상 진행

익명이므로 "**투표하지 않은 사람 = 봇**"이 역산되지 **않음**

죽은 참가자도 이 투표에는 참여 (관전 개념이 없으므로 전원 동시 종료)

이 화면의 카피가 **게임의 반전 지점** — "라이어 게임인 줄 알았지?"를 연출로 전달해야 함

최종 결과 & 봇 티 사유 수집

두 게임의 결과를 나란히 공개한 뒤, 데이터 수집으로 마무리합니다.

화면

최종 결과		GAME OVER
라이어 게임 라이어 승	봇 색출 3명 중 2명 적중	
정체 공개 김정현 · 사람/시민 박진 · 봇/라이어 이현우 · 사람/시민 유민성 · 사람/시민		

왜 봇이라고 생각했나요?		적중자 대상
해당하는 이유 선택 (복수) 문체 완결성 과잉 논리 기억이 정확함 뒤끝 없음 말수 균일 대화 앵커링 실패		
기타 (자유 서술)		
제출		

규칙

두 결과는 **완전히 독립** — "라이어 게임은 졌지만 봇은 맞췄다"가 정상 상태

수집 형식: **사전 정의 태그 + 자유 서술 하이브리드**

순수 데이터 수집 — 봇 지목에 **점수·승패는 걸리지 않음**

현재 **적중자에게만** 사유를 받는 안 — 아래 미확정 항목 참고

검토 중

적중자에게만 사유를 받으면 "**왜 사람을 봇으로 착각했는가**" 데이터가 유실됩니다. 사람이 봇처럼 보이는 순간 역시 산출물로서 가치가 있어, 오답자 사유 수집도 검토 대상입니다.

구현 시 반드시 분기해야 하는 예외 상황들입니다.

상황	처리
투표 동점	재투표. 횟수 제한 없음 — 계속 동점이면 계속 재투표
전원 기권 / 무표	최다 득표자 부재 → 동점과 동일하게 재투표 처리 확인 필요
자기 자신에게 투표	허용. 별도 제약 없음
생사 투표 미투표	기권으로 처리. 과반 기준은 전체 투표자 수 기준 유지 확인 필요
"살린다" 무한 반복	제한 없음. 정보 누적으로 자연 수렴한다는 설계 전제
라이어가 제시어 추측 시간 초과	미입력 = 오답 처리 → 시민 승 확인 필요
봇이 처형당함	일반 참가자와 동일 처리. 봇이라는 사실은 S6까지 비공개
봇이 라이어이며 처형됨	봇이 제시어 추측 수행 — LLM 추론 강점으로 승률 왜곡 가능 (밸런싱 대상)
묘사 단계 재진입	발생하지 않음. 어떤 경로로도 ①로 돌아가지 않음
관전자 발생	발생하지 않음. 1명 사망 = 즉시 종료이므로 관전 상태 자체가 없음

와이어프레임 구현 전 확정이 필요한 값과 결정들입니다.

항목	영향	내용
각 단계 제한시간	밸런싱	묘사 톤당 / 토론+투표 / 최후 변론 / 생사 투표 / 제시어 추측 — 5개 값
묘사 톤 조기 종료	UI	시간이 남았을 때 "넘기기" 버튼을 줄지
발언 방향 결정 주체	UI	시계/반시계를 시스템이 랜덤 결정 vs 방장이 선택
봇 티 사유 수집 범위	산출물	적중자만 vs 전원 — 오답 사유의 데이터 가치 검토
주제·제시어 데이터셋	콘텐츠	직접 제작 vs 외부 조달. 카테고리 수와 난이도 분포 설계 필요
최소·최대 인원	구현	기준 4명 / 예시 8명 — 지원 범위 확정 필요. 인원별 과반 기준이 달라짐
봇 라이어 밸런싱	밸런싱	제시어 추측 정확도에 제약을 걸지 여부